

Вариационная оптимизация моделей глубокого обучения с контролем сложности модели

О. Ю. Бахтеев, В. В. Стрижов, О. С. Гребенькова

bakhteev@phystech.edu; strijov@ccas.ru; grebenkova.os@phystech.edu

В работе исследуется задача построения модели глубокого обучения с возможностью задания ее сложности. Под сложностью модели понимается минимальная длина описания, минимальное количество информации, которое требуется для передачи информации о модели и о выборке. Предлагается метод оптимизации модели, основанный на представлении модели глубокого обучения в виде гиперсети с использованием байесовского подхода, где под гиперсетью понимается сеть, которая генерирует параметры другой сети. Вводятся вероятностные предположения о параметрах моделей глубокого обучения. Предлагается максимизировать вариационную нижнюю оценку байесовской обоснованности модели. Вариационная оценка рассматривается как условная величина, зависящая от задаваемой требуемой сложности модели. Для анализа качества представленного алгоритма проводятся эксперименты на выборках MNIST и CIFAR.

Ключевые слова: *вариационная оптимизация моделей; гиперсети; глубокое обучение; нейронные сети; байесовский подход; заданная сложность модели*

1 Введение

Здесь я пишу свой план работы и вот такие ссылки на следующие работы [1], [2], [3], [4], [5], [6].

2 Постановка задачи

рассматривается задача оптимизации модели глубокого обучения с заранее заданной сложностью модели. Требуется предложить метод оптимизации модели, позволяющий производить порождение новых моделей с заданной сложностью и небольшими вычислительными затратами.

2.1 Название параграфа

Разделы и параграфы, за исключением списков литературы, нумеруются.

3 Заключение

Желательно, чтобы этот раздел был, причём он не должен дословно повторять аннотацию. Обычно здесь отмечают, каких результатов удалось добиться, какие проблемы остались открытыми.

Литература

- [1] Veniat Tom, Denoyer Ludovic. Learning time/memory-efficient deep architectures with budgeted super networks // CVPR. — 2018. P. 3492–3500. URL: <http://ieeexplore.ieee.org/xpl/mostRecentIssue.jsp?punumber=8576498>.
- [2] Saxena Shreyas, Verbeek Jakob. Convolutional neural fabrics // CoRR, 2016. Vol. abs/1606.02492. URL: <http://arxiv.org/abs/1606.02492>.
- [3] Graves Alex. Practical variational inference for neural networks // Advances in Neural Information Processing Systems 24: 25th Annual Conference on Neural Information Processing Systems 2011. Proceedings of a meeting held 12-14 December 2011, Granada, Spain / Eds. John Shawe-Taylor, Richard S. Zemel, Peter L. Bartlett, Fernando C. N.

Pereira, Kilian Q. Weinberger. — 2011. P. 2348–2356. URL: <http://papers.nips.cc/book/advances-in-neural-information-processing-systems-24-2011>.

[4] *Ha David, Dai Andrew M., Le Quoc V.* Hypernetworks // CoRR, 2016. Vol. abs/1609.09106. URL: <http://arxiv.org/abs/1609.09106>.

[5] *Xie Sirui, Zheng Hehui, Liu Chunxiao, Lin Liang.* Snas: Stochastic neural architecture search // CoRR, 2018. Vol. abs/1812.09926. URL: <http://arxiv.org/abs/1812.09926>.

[6] *Wu Bichen, Dai Xiaoliang, Zhang Peizhao, Wang Yangfan, Sun Fei et al.* Fbnet: Hardware-aware efficient convnet design via differentiable neural architecture search // CoRR, 2018. Vol. abs/1812.03443. URL: <http://arxiv.org/abs/1812.03443>.

Received February 25, 2020